Исследовательские проекты по ML и теории управления

Коннектом дрозофилы и ассоциативная память
Биоинформатика и математическая биология

Тимофей Рыко

Доступ и установка

API	Для доступа к API обратитесь к преподавателю.
FreeBuff	Установите FreeBuff. Бесплатные модели: DeepSeek V4.1 Flash, GLM 5.3 Flash и MiMo v2.6 Flash Fast.
OpenCode	Установите OpenCode. Выбор модели: /models. Бесплатно: DeepSeek V4.1 Flash Free, GLM-5.3-Flash Free и MiMo-V2.6-Flash Free.

Материалы курса: github.com/timofeiryko/ai-agents-for-science

На 27.10.2026. В OpenCode бесплатный доступ временный; в FreeBuff действуют лимиты.

Связность грибовидного тела и обучение

Гипотеза

Модель со связями из коннектома дрозофилы достигнет заданной точности различения запахов при меньшем числе обучающих примеров, чем модель со случайной связностью.

Предполагаемый механизм

Меньшее перекрытие активных клеток для разных запахов снижает взаимное влияние записанных ассоциаций.

Данные и схема эксперимента

Источники данных

Hemibrain: связи нейронов PN и KC.
DoOR: ответы рецепторов на запахи.
Модель преобразует входные ответы в активность клеток Кеньона (KC).

Контрольная модель

Перемешанный граф связей с сохранением степени каждого нейрона. Входные данные и правило обучения одинаковы для всех графов.

Метрики: точность при 1, 2, 5, 10 примерах на запах и перекрытие кодов при одинаковом числе активных клеток.

Допущения: синтетический шум в профилях DoOR и отображение ответов рецепторов на входы проекционных нейронов (PN).

Ассоциативная память: теорема для Lean

N запахам соответствуют бинарные коды a_i с k активными клетками.
Пересечение кодов разных запахов не превышает r клеток.

Правило Хебба для меток $y_i \in \{-1, +1\}$:

$$w = \Sigma_i \, y_i a_i$$

Оценка, подлежащая формализации при $k > (N - 1)r$:

$$y_i \langle w, a_i \rangle \geq k - (N - 1)r > 0$$

При $k > (N - 1)r$ знак ответа совпадает с меткой каждого записанного кода.

Выбор вариантов фермента для измерения

Гипотеза: выбор вариантов амилазы по прогнозу активности и неопределённости модели выявит больше активных вариантов, чем случайный отбор.

Данные и методы

FLIP2: измеренные варианты амилазы.
Скрываем значения активности.
Сравниваем случайный отбор,
максимум прогноза и учёт
неопределённости.

Проверка на готовых данных

Бюджет: 200 раскрытых меток.
Открываем метки выбранных вариантов.
Считаем найденные варианты
из верхних 10% по активности.

Критерий: в 1,5 раза больше высокоактивных вариантов, чем при случайном отборе.

Память об ошибках в биоинформатических задачах

Гипотеза: память с правилами обработки данных снизит число ошибок в новых биоинформатических скриптах по сравнению с хранением полных логов.

Задачи и методы

Обработка FASTA и таблиц генов, объединение аннотаций и образцов.
Одна LLM: без памяти, с логами и с обобщёнными правилами ошибок.

Проверка

Скрытые тесты: пропуски, дубликаты, переставленные образцы и ID генов.
Равный контекст и до 3 попыток.
Раздельные задачи для памяти и теста.

Критерий: рост доли полностью корректных решений ≥10 п.п. относительно полных логов.

Моделирование динамики микробных сообществ

Гипотеза: модель с межвидовыми взаимодействиями точнее предскажет рост двух видов при новых начальных пропорциях, чем независимый рост видов.

Данные и модели

Venturelli et al.: временные ряды монокультур и пар видов.
Независимый логистический рост и модель Лотки–Вольтерры.

Проверка переноса

Обучение: монокультуры и смесь 1:1.
Тест: смеси 95:5 и 5:95.
Ошибка прогноза численности и итоговое соотношение видов.

Критерий: снижение ошибки прогноза ≥20% на отложенных начальных пропорциях.

Персонализация прогноза глюкозы

Гипотеза: поправка по первым двум дням наблюдений снизит ошибку прогноза гликемического ответа по сравнению с общей моделью.

Данные и модель

CGMacros: глюкоза и состав еды.
Общая модель обучается
на других участниках.
Поправка — средняя ошибка модели
на данных этого человека.

Проверка персонализации

Первые 2 дня — расчёт поправки.
Следующие дни — тест.
Прогноз: площадь под кривой
прироста глюкозы за 2 часа после еды.

Критерий: медианная ошибка по участникам снизится не менее чем на 10%.

Оценка надёжности прогнозов для молекул

Гипотеза: расхождение прогнозов нескольких моделей лучше выявит ошибки на новых молекулярных каркасах, чем уверенность одной модели.

Данные и методы

BBBP: проникновение веществ
через гематоэнцефалический барьер.
Признаки структуры из RDKit;
одна модель и ансамбль из пяти.

Проверка на новых структурах

В тесте — новые каркасы молекул.
Каждый метод оставляет 80% прогнозов.
Сравниваем долю ошибок
и долю ответов для каждого класса.

Критерий: меньше ошибок среди 80% прогнозов, выбранных по согласованности моделей.

Статья и грант

Проект можно развить в научную статью и подать на конкурс грантов для молодых учёных и специалистов.

Например, в Институте проблем управления РАН.

Источники

FreeBuff: модели и доступ

OpenCode: бесплатные модели

Коннектом: Hemibrain / neuPrint

Ответы на запахи: DoOR

PN–KC связность: Ellis et al., 2024

Lean 4: формализация доказательств

Варианты амилазы: FLIP2

Память агента: Reflexion

Микробные сообщества: Venturelli et al., 2018

Глюкоза и питание: CGMacros

Свойства молекул: MoleculeNet / BBBP

ИПУ РАН: направления исследований